



Machine Learning Project Report

Heart Failure Risk Prediction

Project Summary

Objective

본 프로젝트의 목적은 Heart Disease와 관련된 임상 데이터를 종합적으로 분석하여, 환자의 위험도를 예측하고 위험군을 구조적으로 이해함으로써 의료적 의사결정에 도움이 되는 머신러닝 기반 분석 체계를 구축하는 것이다.

Machine Learning Models Used

Table of Contents

Heart Failure Risk Prediction

Project Summary

Objective

Machine Learning Models Used

Team Members

Table of Contents

Dataset

Dataset

Dataset Selection Rationale

Attribute Information

Preprocessing

Regression :

Simple Linear Regression

Multiple Linear Regression

Random Forest Regresson

Classification:

Perceptron

Logistic Regression

SVM (Support Vector Machine)

Decision Tree

Random Forest

KNN (K-Nearest Neighbors)

LDA (Linear Discriminant Analysis)

Clustering:

K-means Clustering

Agglomerative Clustering

DBSCAN

Team Members

이름	학과	학번
@김다솔	인공지능학과	202421706
@채원 박	인공지능학과	202421718
@채현 이	인공지능학과	202421733

1 [Missing / Outlier Preprocessing](#)

2 [One-hot encoding](#)

3 [Separation of X and y](#)

4 [Train / Test Split](#)

1 [Regression](#)

 [Purpose](#)

0 [Standardization Progress](#)

1 [Regression Model Performance Comparison](#)

2 [Simple Linear Regression](#)

3 [Multiple Linear Regression](#)

3 [Random Forest](#)

4 [Feature Importance](#)

5 [Permutation Importance](#)

6 [Analyzing Feature importance](#)

2 [Classification](#)

 [Purpose](#)

1 [Print Accuracy, Decision region, and Learning c...](#)

2 [Tuning Random Forest parameters](#)

3 [Compare Models performance](#)

4 [Tuning Logistic Regression parameters](#)

5 [Selecting optimal model](#)

6 [Analyzing Feature importance](#)

3 [Clustering](#)

 [Purpose](#)

0 [Standardization Progress](#)

1 [K-means \(k Change performance measurement\)](#)

+ [Silhouette Plot Visualization \(k=2~10\)](#)

2 [K-Means Clustering \(k = 2\)](#)

3 [K-Means Clustering \(k = 4\)](#)

4 [Agglomerative Clustering + Dendrogram](#)

5 [DESCAN](#)

+ [Extended Analysis with Clustering 1](#)

+ [Extended Analysis with Clustering 2](#)



[🚩 Conclusion](#)

[+ Supplement](#)

[? How to use it](#)

[🔗 Colab Notebook](#)

💡 Dataset

📁 Dataset

 FEDESORIANO · UPDATED 4 YEARS AGO

3042

<> Code

Download

⋮

Heart Failure Prediction Dataset

11 clinical features for predicting heart disease events.



k Heart Failure Prediction Dataset

📄 Dataset Selection Rationale

심혈관 질환(CVD)은 전 세계 사망 원인 1위로, 매년 약 1,790만 명이 사망하는 것으로 추정되며, 이는 전 세계 사망자의 31%를 차지한다.

심부전은 심혈관 질환으로 인해 발생하는 흔한 사건이다.

심혈관 질환을 앓고 있거나 고혈압, 당뇨병, 고지혈증 또는 이미 확립된 질병과 같은 하나 이상의 위험 요인이 존재하여 심혈관 위험이 높은 사람들은 조기 발견과 관리가 필요하다.

심혈관 건강은 단순한 의학적 검사 수치뿐 아니라 생활습관(흡연, 운동, 수면, 비만 등)과 밀접하게 연관되어 있다는 연구가 다수 존재하여, 의료 기반 데이터(Heart Failure)와 생활습관 기반 데이터(Lifestyle)를 통합하여 프로젝트를 진행하려 했으나 두 데이터를 통합 시킬 시 서로의 특성이 결측치로 처리되어 예측 모델의 성능이 저하되는 현상이 발생하였다.

이에 의료 기반 데이터를 단독으로 사용하기로 결정하였다.



Heart Failure 데이터셋은 이전에 독립적으로 제공되어 결합되지 않은 5개의 심장 데이터셋이 11개의 공통 특징에 걸쳐 결합되어 지금까지 연구 목적으로 이용 가능한 가장 큰 심장 데이터셋이기에 이번 프로젝트 데이터셋으로 선정하게 되었다.

Attribute Information

	Features	Feature Descriptions
1	Age	age of the patient [years]
2	Sex	sex of the patient [M: Male, F: Female]
3	ChestPainType	chest pain type [TA: Typical Angina, ATA: Atypical Angina, NAP: Non-Anginal Pain, ASY: Asymptomatic]
4	RestingBP	resting blood pressure [mm Hg]
5	Cholesterol	serum cholesterol [mm/dl]
6	FastingBS	fasting blood sugar [1: if FastingBS > 120 mg/dl, 0: otherwise]
7	RestingECG	resting electrocardiogram results [Normal: Normal, ST: having ST-T wave abnormality (T wave inversions and/or ST elevation or depression of > 0.05 mV), LVH: showing probable definite left ventricular hypertrophy by Estes' criteria]
8	MaxHR	maximum heart rate achieved [Numeric value between 60 and 202]
9	ExerciseAngina	exercise-induced angina [Y: Yes, N: No]
10	Oldpeak	oldpeak = ST [Numeric value measured in depression]
11	ST_Slope	the slope of the peak exercise ST segment [Up: upsloping, Flat: flat, Down: downsloping]
12	HeartDisease	output class [1: heart disease, 0: Normal]

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Age             918 non-null   int64
1   Sex             918 non-null   object
2   ChestPainType   918 non-null   object
3   RestingBP       918 non-null   int64
4   Cholesterol     918 non-null   int64
```

총 918개 행, 12개 컬럼

연속형:

Age, RestingBP, Cholesterol, FastingBS, MaxHR, Oldpeak, HeartDisease



```

5  FastingBS      918 non-null    int64
6  RestingECG     918 non-null    object
7  MaxHR          918 non-null    int64
8  ExerciseAngina 918 non-null    object
9  Oldpeak        918 non-null    float64
10 ST_Slope       918 non-null    object
11 HeartDisease   918 non-null    int64
dtypes: float64(1), int64(6), object(5)
memory usage: 86.2+ KB

```

범주형(object):

Sex, ChestPainType, RestingESG,
ExerciseAngina, ST_Slope

결측치는 info 상에서는 없음 (non-null = 918)

0 Preprocessing

1 Missing / Outlier Preprocessing

```

# Cholesterol, RestingBP가 0인 값은 의학적으로 말이 안 되므로 '측정 안 됨/에러'로 보고 NaN으로 바꿈
df['Cholesterol'] = df['Cholesterol'].replace(0, np.nan)
df['RestingBP'] = df['RestingBP'].replace(0, np.nan)

from sklearn.impute import KNNImputer

# KNNImputer로 결측치 채우기
features_for_knn = ['Age', 'RestingBP', 'Cholesterol', 'FastingBS', 'MaxHR', 'Oldpeak']
imputer = KNNImputer(n_neighbors=5)
df[features_for_knn] = imputer.fit_transform(df[features_for_knn])

# 결측치 처리 확인
for col in ['Cholesterol', 'RestingBP']:
    print(f'{col}:')
    print(f'NaN 개수 : {df[col].isna().sum()}')
    print(f'0 개수 : {df[col] == 0}.sum()')

[Cholesterol]
NaN 개수 : 0
0 개수 : 0

[RestingBP]
NaN 개수 : 0
0 개수 : 0

```

Cholesterol, RestingBP가 0인 값은 의학적으로 불가능한 값이므로 결측치 (NaN)로 간주.

KNN Imputer를 사용하여 비슷한 연령대, 혈압, 심박수, Oldpeak 등을 가진 가장 가까운 환자들의 정보를 기반으로 각 feature 간 상관관계를 반영하여 결측치 채움.

2 One-hot encoding

```

# 범주형 변수 원-핫 인코딩
categorical_cols = ['Sex', 'ChestPainType', 'RestingECG',
                    'ExerciseAngina', 'ST_Slope']

df_encoded = pd.get_dummies(df, columns=categorical_cols, drop_first=True)
bool_cols = df_encoded.select_dtypes(include='bool').columns
df_encoded[bool_cols] = df_encoded[bool_cols].astype(int)

df_encoded.head()

```

앞서 확인한 범주형 변수 5개를 One-hot encoding으로 숫자형으로 변환.

3 Separation of X and y

```
X = df_encoded.drop('HeartDisease', axis=1)
y = df_encoded['HeartDisease']
```

모델 학습을 위해 X, y 분리.

Clustering의 경우 X_scaled만 사용하지만 추후 클러스터별 HeartDisease 비율을 보기 위해 y를 따로 보관.

4 Train / Test Split

```
# train / test 나누기
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)

print(X_train.shape, X_test.shape)
```

Regression과 Classification의 경우 Train/Test Split 진행.

1 Regression

Purpose

환자의 심장병 위험도를 0~1 사이의 연속적인 "위험 점수(Risk Score)"로 정량적으로 예측하는 것.

▶ Models Used

0 Standardization Progress

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

print("\n표준화 후 X_scaled shape:", X_scaled.shape)
```


1 Regression Model Performance Comparison

서로 다른 회귀 모델의 예측 성능을 비교하기 위해 MSE, RMSE, MAE, R^2 score 를 주요 평가 지표로 사용하였다.

또한 Actual vs Predicted plot을 통해 각 모델이 실제 심장 질환 위험도를 얼마나 잘 추정하는지 시각적으로 비교하였다.

2 Simple Linear Regression

Age




▶ 평가 결과

Age 단일 변수를 사용하여 심장병 위험도를 예측

예측값이 좁은 범위에 집중되어 실제 위험도 분포를 충분히 반영하지 못함

R^2 값이 낮아 위험도 변화를 거의 설명하지 못함

Oldpeak




▶ 평가 결과

Oldpeak 는 심장병 위험도와 일정한 양의 상관관계를 보임

단일 변수 회귀에서는 설명력이 제한적이며 위험도 구분이 불안정함

Oldpeak 는 중요한 feature이지만 단독으로는 예측 정확도가 낮음

3 Multiple Linear Regression



단일 변수 회귀 대비 예측 성능이 크게 향상됨


여러 생체 변수가 함께 위험도 예측에 기여함을 확인

▶ 평가 결과

예측값 분포가 다양해져 위험도 구분 능력 개선

$R^2 \approx 0.55$ 로, 선형 모델만으로는 한계 존재

3 Random Forest




▶ 평가 결과

단순 다중 선형 회귀 대비 가장 높은 예측 성능을 보임

실제 0/1 패턴을 잘 따라가며 비선형 관계를 효과적으로 학습

데이터 구조를 안정적으로 반영한 예측 결과 확인




▶ 평가 결과

하이퍼파라미터 튜닝 후 수치 지표 소폭 개선되었으나 실제 0/1 패턴을 따르는 능력은 감소

파라미터 제약으로 인한 모델 복잡도 감소로 예측값이 중간에 과도하게 몰림

지표만으로는 판단하는 것이 아닌 시각적 평가 함께 고려해야함을 알 수 있음

4 Feature Importance




Random Forest feature importance를 통해 주요 예측 변수를 분석

MaxHR, ST_Slope, Oldpeak 등 심박수·ST 변화 관련 지표가 가장 큰 영향

혈압, 콜레스테롤 등 전형적인 심혈관 위험 변수들도 중요하게 작용

5 Permutation Importance




Random Forest의 기본 Feature Importance(MDI)는 분기 기준 기반으로 편향 가능

Permutation Importance는 테스트셋 예측 성능 감소를 기준으로 중요도 평가

Sex_M 과 같이 MDI에서는 낮았던 변수도 실제 예측에는 중요한 영향 확인

6 Analyzing Feature importance



Age는 단독 영향은 작지만 평균 이상 구간에서 위험도가 완만히 증가

데이터 밀집도가 낮은 구간에서는 예측 변동성이 존재

Oldpeak는 위험도와 가장 강한 비선형 관계를 보임

Oldpeak 증가에 따라 예측 위험도가 뚜렷하게 상승

2 Classification

Purpose

심장병 여부(HeartDisease)를 0/1로 구분하여, 어떤 환자가 질환을 가지고 있는지 조기에 예측하는 것.

▶ Models Used

1 Print Accuracy, Decision region, and Learning curve

- ▶ Perceptron (accuracy: 0.81)
- ▶ Logistic Regression (accuracy: 0.859)
- ▶ SVM (accuracy: 0.848)
- ▶ Decision Tree (accuracy: 0.815)
- ▶ Random Forest(accuracy: 0.832)
- ▶ KNN(accuracy: 0.853)
- ▶ LDA(accuracy: 0.859)

Accuracy, Precision, Recall, F1-score를 비교 지표로 사용하고, 학습 곡선을 통해 각 모델의 과적합·과소적합 경향을 분석한 결과, Decision Tree와 Random Forest에서 과적합 가능성이 관찰됨

2 Tuning Random Forest parameters

- ▶ Parameter tuning result
- ▶ Tuned Random Forest Decision region, Learning curve
- ▶ 5-fold cross-validation

이에 Random Forest를 GridSearch를 사용해 `n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf` 등을 튜닝하여 테스트 정확도 0.864 및 5-fold 교차검증 평균 정확도 0.8488(표준편차 0.019)을 얻음

3 Compare Models performance

	Classifier	Accuracy	Precision	Recall	F1 Score
0	Perceptron	0.711957	0.775281	0.676471	0.722513
1	SVM	0.717391	0.731481	0.774510	0.752381



2	Logistic Regression	0.896739	0.902913	0.911765	0.907317
3	Decision Tree	0.798913	0.821782	0.813725	0.817734
4	Random Forest	0.831522	0.838095	0.862745	0.850242
5	KNN	0.657609	0.701031	0.666667	0.683417
6	LDA	0.880435	0.884615	0.901961	0.893204

Random Forest의 과적합을 해결한 뒤, 각 모델의 Accuracy, Precision, Recall, F1-score를 출력하여 비교 → Logistic Regression의 정확도가 가장 높은 것을 확인

4 Tuning Logistic Regression parameters

- ▶ L1 Grid search result
- ▶ L2 Grid search result
- ▶ Elastic Net Grid search result

Logistic Regression에는 L1, L2, Elastic Net 규제를 적용하여 하이퍼파라미터 튜닝을 수행한 결과, L2 및 Elastic Net 규제에서 테스트 정확도 **0.886**으로 가장 높은 성능을 달성


- ▶ 5-fold cross validation


5 Selecting optimal model

- ▶ RF와 LR 성능 비교

5-fold 교차검증 **평균 정확도는 0.8079(표준편차 0.023)**로, 교차검증 점수는 다소 낮지만 다른 모델 대비 전반적으로 우수한 성능을 보여 Logistic Regression을 최적 모델로 선정

6 Analyzing Feature importance





성능 최적화와 별도로, L1 규제를 적용한 Logistic Regression을 사용해 특성 중요도를 시각화
 → L1 규제는 계수 일부를 0으로 수축시켜 특성 선택과 해석에 유리하기 때문에, 성능 최적화를 위한 L2 모델과 병행해 사용

양의 방향으로 중요한 변수

- Sex_M
- FastingBS
- ExerciseAngina_Y

⇒ 위의 특성이 나타나면 심장병일 가능성↑

음의 방향으로 중요한 변수

- ChestPainType_NAP
- ChestPainType_ATA
- ChestPainType_TA

⇒ 위의 특성이 나타나면 심장병이 아닐 가능성↑

3 Clustering

Purpose

레이블 없이 환자들을 특성 패턴에 따라 자연스럽게 그룹화하여, 고위험-저위험 환자군을 발견하고 잠재적 요인을 구조적으로 파악하는 것.

▶ Models Used

0 Standardization Progress

k-means는 각 feature의 스케일에 민감하므로 모든 컬럼을 평균 0, 표준편차 1로 맞춤

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)


print("\n표준화 후 X_scaled shape:", X_scaled.shape)
```

Clustering 알고리즘은 모두 거리-밀도 기반 모델이라 스케일에 매우 민감.


따라서 공정한 비교와 안정적 군집 형성을 위해 StandardScaler 적용

1 K-means (k Change performance measurement)

Elbow





Average Silhouette Score



시대별 패션 아이콘 특성

20세기와 21세기의 패션 아이콘의 특성



K=2에서 매우 높고, 그 이후에는 점차 감소.


“클러스터 간 분산 / 클러스터 내부 분산”
비율 관점에서 가장 단순하게 2개로 나누는 게 가장 잘 분리된 구조라는 의미.

k=4 근처에서 가장 낮고, 그 외엔 조금 더 높은 수준.

DB를 기준으로 보면 k=4도 고려해보는 것이 좋음.

여러 지표를 종합하면 구조적으로 가장 안정적인 건 k=2, DB만 보면 k=4도 후보이지만 해석의 직관성과 단순성까지 고려하면 k=2 선택이 무난한 선택이라고 판단.

+ Silhouette Plot Visualization (k=2~10)



대부분 클러스터들이 0.15~0.25 정도 수준에 많이 분포, 음수(잘못 할당된 샘플)도 일부 존재

→ 완벽한 분리 구조는 아님.

그럼에도 불구하고 k=2에서 평균 실루엣이 제일 크기 때문에 “k=2가 완벽하진 않지만 그나마 가장 나은 군집 수”라고 판단.

2 K-Means Clustering (k = 2)

Best k Select + K-Means Results Summary

Best k based on Silhouette score ... ?

[K-means cluster counts]

cluster_kmeans

0 513

1 405

Name: count, dtype: int64

[K-means cluster vs HeartDisease]

HeartDisease 0 1

cluster_kmeans

0 77 436


1 333 72

Silhouette score을 바탕으로 Best K값 결정

Cluster 0: 513명

Cluster 1: 405명

전처리 과정에서 클러스터별 HeartDisease 비율을 확인하기 위해 따로 저장한 y를 사용하여 클러스터별 HeartDisease 비율 확인.



Cluster 0 → High-risk group

HeartDisease=1 (심장병 O): 약 85%


HeartDisease=0 (심장병 X): 약 15%

Cluster 1 → Low-risk group

HeartDisease=1: 약 18%

HeartDisease=0: 약 82%

PCA 2D Visualization + Centroid Display



PCA 2D 상에서 Cluster 0과 1이 어느 정도 구분되지 만, 경계가 완전히 분리되지는 않음.


일부 영역은 겹쳐 있고, 군집 경계 근처에는 섞여 있는 포인트도 많음.

Centroid는 각 클러스터 내부의 평균 위치를 나타냄.

→ 두 중심점이 꽤 떨어져 있음.

→ 두 집단이 다른 특성을 가진다는 것을 시각적으로 확인 가능.

t-SNE Visualization




t-SNE는 비선형 차원축소로 고차원에서의 인접 관계를 2D에 최대한 유지하려고 함.

그림에서 Cluster 0과 Cluster 1이 여러 덩어리로 나뉘어 있지만 대체로 서로 다른 영역을 차지하여 섞이는 부분은 상대적으로 적은 편.

고차원에서의 거리 구조도 "두 그룹으로 나뉜다"는 것을 지지하는 시각화

Cluster Centers Heatmap



Cluster 0 (고위험군)의 특징

1. Cholesterol 매우 높음
 - cluster 0의 Cholesterol 평균이 cluster 1보다 훨씬 높음

Cluster 1 (저위험군)의 특징

1. Cholesterol 낮음

- 심혈관계 위험과 직접적으로 연관되는 대표 요인

2. RestingBP ↑

- 고혈압은 심장병 위험의 대표적 요인

3. Age ↑

- cluster 0의 평균 나이가 cluster 1보다 약간 더 높음
- 나이는 위험도에 중요한 역할

4. MaxHR ↓

- 운동 시 심장 기능이 낮음을 의미

5. Oldpeak ↑

- Oldpeak는 심장 스트레스 지표
- cluster 0이 cluster 1에 비해 높아 "심근허혈 가능성 ↑"

2. RestingBP ↓

3. Oldpeak ↓

4. MaxHR 높음


→ 전반적으로 건강지표가 양호한 집단

→ 실제로 HeartDisease 비율도 약 18%

K-means Cluster Profiling (summary table + boxplot)

[K-means 클러스터 프로파일(평균 값)]

	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	Sex_M	ChestPainType_AT	ChestPainType_NP	ChestPainType_TA	RestingECG_Normal	RestingECG_ST	ExerciseAngina_Y	ST_Slope_Flat	ST_Slope_Up
cluster_kmeans															
0	56.510721	135.267836	251.024172	0.306043	125.750487	1.368616	0.871345	0.042885	0.165692	0.050682	0.541910	0.235867	0.649123	0.849903	0.046784
1	49.711111	129.071605	237.712593	0.140741	150.817284	0.277778	0.686420	0.372840	0.291358	0.049383	0.676543	0.140741	0.093827	0.059259	0.916049




3 K-Means Clustering (k = 4)

- k=2는 HeartDisease의 high-risk/low-risk 두 그룹으로 classification과 매우 유사한 구조를 가짐
- 수업시간에 배우진 않았지만 Davies-Bouldin 지표가 k=4에서 가장 낮게 나타나 군집 간 분리가 가장 잘 되어 있음을 보여주었기에 숨겨진 구조를 찾기에 적절하다고 생각해 k=4 분석을 추가함.

K-Means Results Summary (k = 4)

```
[Cluster vs HeartDisease]
HeartDisease  0  1
cluster_k4
0             26  20
1             59 318
2            304  53
3             21 117
```



Cluster 0 → Moderate-risk group

- HeartDisease = 1: 약 43%
- HeartDisease = 0: 약 57%

Cluster 1 → High-risk group

- HeartDisease = 1: 약 84%
- HeartDisease = 0: 약 16%


Cluster 2 → Low-risk group

- HeartDisease = 1: 약 15%
- HeartDisease = 0: 약 85%

Cluster 3 → Very High-risk group


- HeartDisease = 1: 약 85%
- HeartDisease = 0: 약 15%

PCA 2D Visualization + Centroid Display



각 클러스터는 전반적으로 서로 다른 영역에 중심을 두고 분포하는 경향을 보임.

다만 일부 클러스터 간에는 경계가 명확히 분리되지 않고 겹치는 영역이 존재하며 특히 중심부 인근에서는 여러 클러스터의 데이터 포인트가 혼재되어 나타남.




→ PCA가 고차원 데이터를 2차원으로 축소하는 과정에서 정보 손실이 발생하기 때문에 해석할 수 있음.

각 centroid가 서로 비교적 떨어진 위치에 분포하고 있음 → 클러스터들이 전반적으로 다른 특성 공간을 중심으로 형성됨.

따라서 PCA 시각화 결과를 통해, 일부 중첩은 존재하지만 centroid 간 거리와 전체 분포를 고려할 때 각 클러스터는 서로 다른 특성을 가진 집단으로 해석 가능함을 확인할 수 있다.

t-SNE Visualization





4 개의 클러스터는 대체로 서로 다른 공간을 차지하며 특정 클러스터 간 일부 인접 영역을 제외하면 심각하게 섞이는 양상은 제한적.

특히 일부 클러스터는 다른 클러스터와 명확히 떨어진 위치에 독립적으로 형성되어 있어, 고차원 공간에서도 해당 집단이 뚜렷한 특성 차이를 가진 그룹임을 시사함.

따라서 t-SNE 시각화 결과는 K-means로 분리된 4개의 클러스터가 고차원 데이터 공간에서도 의미 있는 구조적 차이를 가지고 존재함을 시각적으로 뒷받침함.

Cluster Centers Heatmap





Cluster 0 특징

- Age ↓
- RestingBP ↓
- Cholesterol ↓
- MaxHR ↑
- 전반적으로 심혈관 위험 지표 낮음

Cluster 1 특징

- Age ↑
- Cholesterol ↑
- MaxHR ↓
- 운동 시 심박 반응 낮은 편

Cluster 2 특징

- RestingBP ↑
- MaxHR ↑
- 혈압·심박 관련 지표가 두드러짐

Cluster 3 특징


- Age ↑↑
- RestingBP ↑
- Cholesterol ↑↑
- 전반적인 심혈관 위험 지표 가장 높음

K-means Cluster Profiling (summary table + boxplot)


[K-means 클러스터 프로파일 (평균 값)]

	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	Sex_M	ChestPainType_ATA	ChestPainType_NAP	ChestPainType_TA	RestingECG_Normal	RestingECG_ST	ExerciseAngina_Y	ST_Slope_Flat	ST_Slope_Up
cluster_k4															
0	54.826087	136.413043	232.978261	0.282609	147.891304	1.036957	0.782609	0.000000	0.000000	1.0	0.478261	0.173913	0.130435	0.478261	0.434783
1	54.973475	132.528912	250.490186	0.244032	126.594164	1.322546	0.840849	0.055703	0.177719	0.0	0.748011	0.000000	0.623342	0.880637	0.026525
2	49.635854	129.114846	238.409524	0.131653	151.605042	0.263025	0.686275	0.406162	0.310924	0.0	0.694678	0.106443	0.095238	0.028011	0.949580
3	59.101449	140.101449	252.065217	0.449275	122.746377	1.263768	0.920290	0.050725	0.181159	0.0	0.000000	0.956522	0.695652	0.695652	0.188406






4 Agglomerative Clustering + Dendrogram




Hierarchical Clustering를 적용한 결과 자연스럽게 두 개의 큰 그룹으로 분리됨을 확인할 수 있음.

Dendrogram에서는 유사한 데이터가 낮은 위치에서 먼저 합쳐지고 가장 위에서 두 갈래로 크게 나뉘는 구조가 확인됨.




PCA 시각화에서는 이 두 군집이 왼쪽과 오른쪽으로 비교적 뚜렷하게 분포하며 Agglomerative가 K-means와 유사하게 두 개의 안정적인 패턴을 찾았다는 것을 보여줌.

5 DESCAN



→ k-distance 그래프 기반 eps 선택

→ $\text{eps} = 3.8$



DBSCAN 결과

```
DBSCAN labels: [-1  0  1]
DBSCAN silhouette (노이즈 제외): 0.2521820748720697
```

```
[ DBSCAN 클러스터별 개수 ]
cluster_dbscan
-1      7
 0    867
 1     44
Name: count, dtype: int64
```

```
[ DBSCAN 클러스터별 HeartDisease 분포 ]
HeartDisease  0    1
cluster_dbscan
-1             4    3
 0          382  485
 1           24   20
```

대부분의 데이터는 Cluster 0에 몰려 있고 Cluster 1은 작은 부집단 형태로 나타남.

노이즈는 단 7개로 많지 않았음.

두 군집 모두 HeartDisease가 섞여 있어 DBSCAN이 뚜렷한 위험군 패턴을 잡아내지 못한다는 것을 알 수 있음.

Sihouette Score: 0.25

→ 군집이 잘 분리되지 않았다는 의미

이 데이터에서는 DBSCAN 적합도 낮음.


+ Extended Analysis with Clustering 1

클러스터를 feature로 활용한 지도학습 모델

- 위에서 training한 결과(k=2)를 지도학습 모델에 넣었을 때 예측 성능이 좋아지는가?
- cluster_kmeans를 새로운 feature로 사용
- 실제 HeartDisease 예측에 쓸모가 있는지 검증

Top 10 Important Features (Cluster-Augmented Model)

```
cluster_kmeans    0.131588
ST_Slope_Up      0.102097
MaxHR            0.097885
Oldpeak          0.087544
Cholesterol       0.074718
RestingBP        0.073657
Age              0.072503
ST_Slope_Flat    0.069966
ExerciseAngina_Y 0.056300
cluster_agg      0.050309
dtype: float64
```



cluster_kmeans — (Importance $\approx$ 0.128)

- K-means 클러스터링이 HeartDisease 예측 모델에서 가장 강력한 feature로 작동함.
- 즉, clustering 자체가 의미 있는 환자 분류를 수행함을 나타냄.
- 비지도학습이 실제 지도학습 성능을 향상시키는 효과를 보임.

+ Extended Analysis with Clustering 2

클러스터별 각각 HeartDisease 예측 모델 학습

- 고위험군 클러스터 내부에서 심장병 여부를 결정하는 추가 요인이 무엇인지, 저위험군에서는 어떤 요인이 위험을 증가시키는지 분석

```
===== Cluster 1 =====
RestingBP    0.148125
Age          0.136726
Oldpeak      0.135686
Cholesterol  0.124522
MaxHR        0.118677
dtype: float64
```

저위험군(cluster 1)

- RestingBP > Age > Cholesterol 순으로 위험요인
- 전형적인 "저위험군" 패턴

```
===== Cluster 0 =====
MaxHR        0.175037
Cholesterol   0.145960
RestingBP    0.130757
Oldpeak      0.123755
Age          0.113292
dtype: float64
```

고위험군(cluster 2)

- MaxHR > Cholesterol > RestingBP 순으로 위험요인
- 여러 위험요인이 복합적으로 작동하는 고위험 의료 패턴

Conclusion

+ Supplement

심혈관 건강은 단순한 의학적 검사 수치 뿐 아니라 흡연, 운동, 수면, 비만 등 생활 습관 요인과의 밀접하게 연관되어 있다.

따라서 향후에는 현재 분석한 Heart Failure 의료 데이터에 더해 Lifestyle 데이터셋을 추가로 결합하여 분석을 확장할 계획이다.

이를 통해 의료 정보 + 생활 습관 정보를 함께 반영한 더 현실적이고 정밀한 심혈관 위험 예측 모델 구축이 가능하다.

? How to use it

1. 환자의 기본 검사 수치만으로 위험도 예측 가능

→ 진료 초기에 고위험군을 빠르게 선별하여 검사 우선순위를 조정할 수 있음.

2. 군집 기반 환자 유형 파악

→ K-means가 찾은 고위험/저위험 패턴을 활용하면 환자가 현재 어떤 그룹에 속하는지 실시간으로 판단 가능.

3. 개인화 진료 전략 제안

→ Oldpeak, ST_Slope 등 핵심 위험 요인이 높은 환자에게 운동처방, 추가 검사, 생활 개선 행동을 구체적으로 안내 가능.

Colab Notebook

Regression →  [Google Colab](#)

Classification →  [Google Colab](#)

Clustering →  [Google Colab](#)